Grado en Matemáticas

Entrega Modelos Estadísticos

El teorema de Fisher en modelos de regresión lineal múltiple

-31 de marzo de 2025-

Autor: Sergio de María Saiz

Índice

1. Prerrequisitos del tratamiento del problema **3**

2. Planteamiento y resolución del ejercicio. **6**

1. Prerrequisitos del tratamiento del problema

Es esta sección principal haremos referencia a los principales resultados y definiciones clave para la construcción del resultado final al que queremos llegar.

Definición 1 (**Modelo de regresión lineal múltiple (Versión escalar)**). *Sea* $x_i = (x_{i1}, \dots, x_{ip})^T$ *para* $i = 1, \dots, n$ *vectores fijos en* $\mathbb{R}^p$*, y sean* $Y_1, \dots, T_n$ *variables aleatorias tales que*

$$Y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i, \ i = 1, \dots, n,$$

donde $\beta_0, \beta_1, \dots, \beta_p$ *son números relaes, y donde* $\varepsilon_i \overset{ind}{\sim} (0, \sigma^2), \ i = 1, \dots, n$

Definición 2 (**Modelo de regresión lineal múltiple (Versión matricial)**). *Sean*

$$\boldsymbol{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, \quad \boldsymbol{X} = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

de modo que $\boldsymbol{Y}$ *es un vector* $n \times 1$*,* $\boldsymbol{X}$ *es una matriz* $n \times (p+1)$*,* $\boldsymbol{\beta}$ *es un vector* $(p+1) \times 1$*, y* $\boldsymbol{\varepsilon}$ *es un vector* $n \times 1$*. Entonces podemos expresar el modelo de regresión lineal múltiple como*

$$\boldsymbol{Y} = \boldsymbol{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \text{con} \quad \boldsymbol{\varepsilon} \sim (\boldsymbol{0}_n, \sigma^2 \boldsymbol{I}_n).$$

A menudo nos referimos a la matriz $\boldsymbol{X}$ *como la matriz de diseño y a los valores observados de las variables explicativas* $\boldsymbol{x}_1, \dots, \boldsymbol{x}_n$ *como los puntos de diseño. Los errores están incorrelados.*

Definición 3 (**Estimador de** $\boldsymbol{\beta}$). *Dado* $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^T$*, definimos el estimador de* $\boldsymbol{\beta}$*, como* $\hat{\boldsymbol{\beta}} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p)$*, donde* $\hat{\beta}_i$ *es el estimador de* β_i*, para todo* $i = 1, \dots, p$

Definición 4 (**Estimadores OLS para** $\boldsymbol{\beta}$ **y** σ^2). *Sea* $Q_n(\boldsymbol{\beta}) = ||\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta}||_2^2 = \varepsilon(\beta)^T \varepsilon(\beta)$*, donde* $\varepsilon(\beta) = \boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta}$*. Entonces, aplicando el método de mínimos cuadrados a la obtención de una expresión para el vector de estimadores de* $\boldsymbol{\beta}$ *y para* σ^2*, obtenemos, suponiendo que es invertible la matriz simétrica* $(\boldsymbol{X}^T\boldsymbol{X})$

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T\boldsymbol{Y} \hat{\sigma^2} = \frac{\varepsilon(\hat{\beta})^T \varepsilon(\hat{\beta})}{n - (p+1)}$$

Definición 5 (**Vector de residuos del modelo de regresión lineal múltiple**). *Sea* $\hat{\boldsymbol{\beta}}$ *el estimador del vector* $\boldsymbol{\beta}$*. Definimos el vector de residuos del modelo de regresión lineal múltiple como*

$$\hat{\boldsymbol{\varepsilon}} = \boldsymbol{\varepsilon}(\hat{\boldsymbol{\beta}}) = \boldsymbol{Y} - \boldsymbol{X}\hat{\boldsymbol{\beta}}$$

Definición 6 (**Vector de valores ajustados del modelo de regresión lineal múltiple**). *Definimos el vector de valores ajustados del modelos de regresión lineal múltiple como*

$$\hat{\boldsymbol{Y}} = \boldsymbol{X}\hat{\boldsymbol{\beta}} = \boldsymbol{H}\boldsymbol{Y}$$

Donde $\boldsymbol{H}$ *es la matriz hat (llamada así porque al multiplicar a* $\boldsymbol{Y}$*, esta le pone un gorro dando como resultado el vector de valores ajustados* $\hat{\boldsymbol{Y}}$*) se define como*

$$\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T$$

Proposición 1.1. *La matriz Hat* $\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T$ *cumple las siguientes propiedades:*

- *Es idempotente, esto es* $\boldsymbol{H^2} = \boldsymbol{H}$
- $tr(\boldsymbol{H}) = p + 1$
- $\boldsymbol{H}$ *es una matriz simétrica*

Demostración. En efecto,

- $\boldsymbol{H}^2 = \boldsymbol{H}$ ya que $\boldsymbol{H}^2 = \boldsymbol{X}(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T\boldsymbol{X}(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T = \boldsymbol{X}(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T = \boldsymbol{H}$
- $tr(\boldsymbol{H}) = tr(\boldsymbol{X}(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T)$ y sabiendo que $tr(AB) = tr(BA)$, y que $\boldsymbol{X}^T\boldsymbol{X}$ es matriz de dimensión $p+1$, entonces, $tr(\boldsymbol{X}(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T) = tr((\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T\boldsymbol{X}) = p+1$
- $\boldsymbol{H}^T = (\boldsymbol{X}(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T)^T = \boldsymbol{X}(\boldsymbol{X}(\boldsymbol{X}^T\boldsymbol{X})^{-1})^T = \boldsymbol{X}((\boldsymbol{X}^T\boldsymbol{X})^{-1})^T\boldsymbol{X}^T$, por ser $(\boldsymbol{X}^T\boldsymbol{X})^{-1}$ simétrica ya que $(\boldsymbol{X}^T\boldsymbol{X})$ es simétrica y suponemos que existe su inversa.

□

Definición 7 (**Estimadores ML para $\boldsymbol{\beta}$ y σ^2**). *Supongamos ahora que* $\varepsilon_i \overset{ind}{\sim} \mathcal{N}(0, \sigma^2)$ *en el modelo. Sea* $Q_n(\boldsymbol{\beta}) = ||\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta}||_2^2 = \varepsilon(\beta)^T\varepsilon(\beta)$*, donde* $\varepsilon(\beta) = \boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta}$*. Entonces, aplicando el método de máxima verosimilitud a la obtención de una expresión para el vector de estimadores de* $\boldsymbol{\beta}$ *y para* σ^2*, obtenemos, suponiendo que es invertible la matriz simétrica* $(\boldsymbol{X}^T\boldsymbol{X})$

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T\boldsymbol{Y}, \ \hat{\sigma^2} = \frac{\varepsilon(\hat{\beta})^T\varepsilon(\hat{\beta})}{n}$$

Observación. Podemos hallar una serie de diferencias entre los estimadores de máxima verosimilitud y de mínimos cuadrados obtenidos para $\boldsymbol{\beta}$ y σ^2.

- Para los estimadores obtenidos por el método de máxima verosimilitud (ML), además de suponer que los errores del modelo son independientes y se hallan idénticamente distribuidos, suponemos que distribuyen como una normal, esto es $\varepsilon_i \overset{ind}{\sim} \mathcal{N}(0, \sigma^2)$, mientras que para los estimadores obtenidos por el método de mínimos cuadrados, solo suponemos que son independientes y se hallan idénticamente distribuidos, esto es $\varepsilon_i \overset{ind}{\sim} (0, \sigma^2)$
- Los estimadores obtenidos tanto por el método de máxima verosimilitud (ML), como por el método de mínimos cuadrados (OLS), coinciden en l estimación de $\boldsymbol{\beta}$, esto es $\hat{\boldsymbol{\beta}}_{MLE} = \hat{\boldsymbol{\beta}}_{OLS}$. Esto no sucede con los estimadores de σ^2, que son distintos.

El resultado que vamos a demostrar supone normalidad en el muestreo de los errores del modelo de regresión lineal múltiple.

Definición 8 (**Distribución chi-cuadrado central con n grados de libertad**). *Sea* $\boldsymbol{U} = (U_1, \ldots, U_n)^T$ *un vector creado a partir de una m.a.s. de una población* $U \sim \mathcal{N}(0, 1)$*, es decir,* $\boldsymbol{U} \sim \mathcal{N}_n(0, \boldsymbol{I}_n)$*. Definimos la distribución chi-cuadrado (central) con n grados de libertad como aquella correspondiente a la forma cuadrática asociada a la matriz* $\boldsymbol{I}_n$*, es decir,*

$$\boldsymbol{U}^T\boldsymbol{U} = \sum_{i=1}^{n} U_i^2 \sim \chi_n^2.$$

Definición 9 (Distribución chi-chadrado no central con n grados de libertad). *Sea $\boldsymbol{U} = (U_1, \ldots, U_n)^T$ un vector creado a partir de una muestra de observaciones independientes pero no idénticamente distribuidas ya que $U_i \sim \mathcal{N}(\mu_i, 1)$. Definimos la distribución chi-cuadrado (no central) con n grados de libertad y parámetro de centralización*

$$\nu = \boldsymbol{\mu}^T \boldsymbol{\mu} = \sum_{i=1}^{n} \mu_i^2 \geq 0,$$

donde $\boldsymbol{\mu} = E[\boldsymbol{U}] = E[(U_1, \ldots, U_n)^T] = (\mu_1, \ldots, \mu_n)^T$, como aquella correspondiente a la forma cuadrática asociada a la matriz $\boldsymbol{I}_n$, es decir,

$$\boldsymbol{U}^T \boldsymbol{U} = \sum_{i=1}^{n} U_i^2 \sim \chi_n^2(\nu).$$

Observación. Veamos una serie de propiedades fundamentales del muestreo de las chi-cuadrado:

- Claramente si el parámetro de centralización es cero, esto es $\nu = 0$, entonces tenemos que distribuye como una chi-cuadrado central
- La distribución chi-cuadrado central puede definirse a partir de un caso de muestreo mucho mas general. En efecto, si $\boldsymbol{U} = (U_, \ldots, U_n)^T$ es un vector creado a partir de una muetsra de observaciones independientes pero no idénticamente distribuidas $U_i \overset{ind}{\sim} \mathcal{N}(\mu_i, \sigma_i^2)$, entonces

$$(\boldsymbol{U} - \boldsymbol{\mu})^T \operatorname{diag}^{-1}\{\sigma_1^2, \ldots, \sigma_n^2\}(\boldsymbol{U} - \boldsymbol{\mu}) = \sum_{i=1}^{n} \frac{(U_i - \mu_i)^2}{\sigma_i^2} \sim \chi_n^2.$$

- Al igual que la distrubución chi-cuadrado central, la distribución chi-cuadrado no central también se puede definir a partir de un caso de muestreo mucho mas general. En efecto, si $\boldsymbol{U} = (U_1, \ldots, U_n)^T$ es un vector creado a partir de una muestra de observaciones independientes pero no idénticamente distribuidas $U_i \overset{ind}{\sim} \mathcal{N}(\mu_i, \sigma_i^2)$, entonces

$$\boldsymbol{U}^T \operatorname{diag}^{-1}\{\sigma_1^2, \ldots, \sigma_n^2\}\boldsymbol{U} = \sum_{i=1}^{n} \frac{U_i^2}{\sigma_i^2} \sim \chi_n^2(\nu).$$

Teorema 1.1. *Sea $\mathbf{U} = (U_1, \ldots, U_n)^T$ es un vector creado a partir de una muestra de observaciones independientes pero no idénticamente distribuidas $U_i \overset{ind}{\sim} \mathcal{N}(\mu_i, \sigma^2)$, y $\mathbf{A}$ una matriz simétrica de dimensión n. Entonces, se tiene que*

$$\frac{1}{\sigma^2}\mathbf{U}^T \mathbf{A} \mathbf{U} \sim \chi_r^2(\nu),$$

con $r = tr(\mathbf{A})$ y $\nu = \frac{1}{\sigma^2}\mu^T \mathbf{A}\mu$, si y sólo si $\mathbf{A}$ es idempotente.

Teorema 1.2. *Sea $\mathbf{U} = (U_1, \ldots, U_n)^T$ es un vector creado a partir de una muestra de observaciones independientes pero no idénticamente distribuidas $U_i \overset{ind}{\sim} \mathcal{N}(\mu_i, \sigma^2)$, y $\mathbf{A}_i$, $i = 1, 2$ dos matrices $n \times n$ simétricas. Entonces, se tiene que las variables aleatorias $\mathbf{U}^T \mathbf{A}_i \mathbf{U}$, $i = 1, 2$, son independientes si y sólo si*

$$\mathbf{A}_1 \mathbf{A}_2 = 0_{n \times n}.$$

2. Planteamiento y resolución del ejercicio.

El resultado a demostrar es un resultado análogo al teorema de Fisher que veíamos en la asignatura de estadística de 2º de Carrera. Antes de su demostración, daremos una serie de lemas y resultados que ayudarán en la demostración de este.

Lema 1. *Bajo normalidad de los errores,* $\hat{\boldsymbol{\beta}} \sim \mathcal{N}_{p+1}(\boldsymbol{\beta}, \sigma^2(\boldsymbol{X}^T\boldsymbol{X})^{-1})$

Demostración. En efecto, por cómo se ha definido el modelo de regresión lineal multivariante asumiendo normalidad en la distribución de los errores, tenemos que por la Definición 2, $\boldsymbol{Y} = \boldsymbol{X\beta} + \boldsymbol{\varepsilon}, \quad \text{con} \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\boldsymbol{0}_n, \sigma^2\boldsymbol{I}_n)$. De este modo, podemos asegurar que $\boldsymbol{Y} \sim \mathcal{N}(\boldsymbol{X\beta}, \sigma^2 I_n)$. Veamos ahora que $E[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}$ y que $Var[\hat{\boldsymbol{\beta}}] = \sigma^2(\boldsymbol{X}^T\boldsymbol{X})^{-1}$.

- $E[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta}$. En efecto, $E[\hat{\boldsymbol{\beta}}] = E[(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T\boldsymbol{Y}] = E[(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T(\boldsymbol{X\beta} + \boldsymbol{\varepsilon})] = E[\boldsymbol{\beta}] + (\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T E[\boldsymbol{\varepsilon}] = \boldsymbol{\beta}$

- $Var[\hat{\boldsymbol{\beta}}] = \sigma^2(\boldsymbol{X}^T\boldsymbol{X})^{-1}$. En efecto, como sabemos que $Var[\boldsymbol{AX}] = \boldsymbol{A}Var[\boldsymbol{X}]\boldsymbol{A}^T$, obtenemos que, $Var[\hat{\boldsymbol{\beta}}] = Var[(\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T\boldsymbol{Y}] = Var[\boldsymbol{AY}]$ donde $\boldsymbol{A} = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T$. Entonces $Var[\boldsymbol{AY}] = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\boldsymbol{X}^T Var[\boldsymbol{Y}]\boldsymbol{X}((\boldsymbol{X}^T\boldsymbol{X})^{-1})^T$. Como hemos supuesto en la Definición 4 que la matriz $(\boldsymbol{X}^T\boldsymbol{X})$ es invertible, sabiendo que es simétrica, es trivial ver que su inversa existe y es simétrica también. Por lo que obtenemos que $(\boldsymbol{X}^T\boldsymbol{X})^{-1}Var[\boldsymbol{Y}] = (\boldsymbol{X}^T\boldsymbol{X})^{-1}\sigma^2$

□

Lema 2. *Bajo normalidad de los errores,* $\frac{n\hat{\sigma^2}_{MLE}}{\sigma^2} \sim \chi^2_{n-(p+1)}$

Demostración. En efecto, dado $\frac{n\hat{\sigma^2}_{MLE}}{\sigma^2}$, por la Definición 7 del estimador de máxima verosimilitud para σ^2, sabemos que este viene dado por $\hat{\sigma^2}_{MLE} = \frac{\varepsilon(\hat{\beta})^T\varepsilon(\hat{\beta})}{n}$, por lo que podemos expresar $\frac{n\hat{\sigma^2}_{MLE}}{\sigma^2} = \frac{n(\frac{\varepsilon(\hat{\beta})^T\varepsilon(\hat{\beta})}{n})}{\sigma^2} = \frac{\varepsilon(\hat{\beta})^T\varepsilon(\hat{\beta})}{\sigma^2}$ y por como hemos definido en la Definición 4 el valor de $\varepsilon(\hat{\boldsymbol{\beta}}) = \boldsymbol{Y} - \boldsymbol{X}\hat{\boldsymbol{\beta}} = \boldsymbol{Y} - \hat{\boldsymbol{Y}}$. Queremos probar que dicho estimador distribuye como una chi-cuadrado central con $n-(p+1)$ grados de libertad. Por lo que tratemos de emplear los Teoremas 1.1 y 1.2 para llegar a este resultado. Para ver el número de grados de libertad podemos emplear el Teorema 1.1. Definimos $\boldsymbol{A} = (\boldsymbol{I}_n - \boldsymbol{H})$. Demostremos que es idempotente. En efecto, $\boldsymbol{A}^2 = \boldsymbol{AA} = (\boldsymbol{I}_n - \boldsymbol{H})(\boldsymbol{I}_n - \boldsymbol{H}) = \boldsymbol{I}_n^2 - 2\boldsymbol{H} + \boldsymbol{H}^2 = \boldsymbol{I}_n - \boldsymbol{H}$, por lo que $\boldsymbol{A} = (\boldsymbol{I}_n - \boldsymbol{H})$ es idempotente, por la Proposición 1.1. Por otra parte, por la Definición 2 y por la hipótesis del lema, sabemos que $\boldsymbol{Y} \overset{ind}{\sim} \mathcal{N}(\boldsymbol{X\beta}, \sigma^2\boldsymbol{I}_n)$, por lo que $Y_i \overset{ind}{\sim} \mathcal{N}(\beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}, \sigma^2)$. Entonces, por el Teorema 1.1, como $\boldsymbol{A}$ es idempotente, tenemos que $\frac{1}{\sigma^2}\boldsymbol{Y}^T\boldsymbol{AY} \sim \chi^2_r(\nu)$,donde $r = tr(\boldsymbol{A}) = tr(\boldsymbol{I}_n) - tr(\boldsymbol{H})$ y por la Proposición 1.1, tenemos que $r = n - (p+1)$ como queríamos probar.

Observamos ahora lo siguiente. Como $\boldsymbol{A}$ es idempotente, podemos escribir $\frac{1}{\sigma^2}\boldsymbol{Y}^T\boldsymbol{AY} = \frac{1}{\sigma^2}\boldsymbol{Y}^T(\boldsymbol{AA})\boldsymbol{Y}$, y como $\boldsymbol{A}^T = (\boldsymbol{I}_n - \boldsymbol{H})^T = (\boldsymbol{I}_n - \boldsymbol{H}) = \boldsymbol{A}$, por ser $\boldsymbol{H}$ simétrica por la Proposición 1.1, $\frac{1}{\sigma^2}\boldsymbol{Y}^T(\boldsymbol{AA})\boldsymbol{Y} = \frac{1}{\sigma^2}\boldsymbol{Y}^T(\boldsymbol{A}^T\boldsymbol{A})\boldsymbol{Y}$ y aplicando la propiedad asociativa del producto de matrices, obtenemos $\frac{1}{\sigma^2}(\boldsymbol{AY})^T(\boldsymbol{AY}) = \frac{1}{\sigma^2}(\boldsymbol{Y} - \hat{\boldsymbol{Y}})^T(\boldsymbol{Y} - \hat{\boldsymbol{Y}})$, y ahora definiendo los vectores $\boldsymbol{Y'} = \frac{(\boldsymbol{Y} - \hat{\boldsymbol{Y}})}{\sigma} \overset{ind}{\sim} \mathcal{N}(\boldsymbol{0}_{n-(p+1)}, \boldsymbol{I}_{n-(p+1)})$, entonces $\frac{1}{\sigma^2}(\boldsymbol{Y} - \hat{\boldsymbol{Y}})^T(\boldsymbol{Y} - \hat{\boldsymbol{Y}}) = \boldsymbol{Y'}^T\boldsymbol{Y'}$, y por la Observación 1, y por la Definición 8 de distribución chi-cuadrado de $n-(p+1)$ grados de libertad, obtenemos que, en efecto, $\frac{n\hat{\sigma^2}_{MLE}}{\sigma^2} \sim \chi^2_{n-(p+1)}$ como queríamos demostrar. □

Estamos en condiciones de demostrar el teorema.

Teorema 2.1. *Bajo normalidad de los errores, la distribución (exacta) de los estimadores de β y σ^2 son*

$$\hat{\boldsymbol{\beta}} \sim \mathcal{N}_{p+1}(\boldsymbol{\beta}, \sigma^2(\boldsymbol{X^T X})^{-1})$$

$$\frac{n\hat{\sigma}^2_{MLE}}{\sigma^2} = \frac{||\boldsymbol{Y} - \boldsymbol{X}\hat{\boldsymbol{\beta}}||_2^2}{\sigma^2} \sim \chi^2_{n-(p+1)}.$$

siendo ambos estimadores independientes.

Demostración. Por los Lemas 1 y 2 queda justificada la distribución de ambos estimadores. Además, por la construcción de la demostración del Lema 2, como $\boldsymbol{A} = (\boldsymbol{I}_n - \boldsymbol{H})$ es idempotente, $\frac{n\hat{\sigma^2}_{MLE}}{\sigma^2} = \frac{\varepsilon(\hat{\beta})^T\varepsilon(\hat{\beta})}{\sigma^2} = \frac{1}{\sigma^2}(\boldsymbol{Y} - \hat{\boldsymbol{Y}})^T(\boldsymbol{Y} - \hat{\boldsymbol{Y}}) = \frac{1}{\sigma^2}(\boldsymbol{AY})^T(\boldsymbol{AY}) = \frac{1}{\sigma^2}\boldsymbol{Y}^T(\boldsymbol{A}^T\boldsymbol{A})\boldsymbol{Y} = \frac{1}{\sigma^2}\boldsymbol{Y}^T(\boldsymbol{AA})\boldsymbol{Y} = \frac{1}{\sigma^2}\boldsymbol{Y}^T\boldsymbol{AY}$, donde sabemos que $\boldsymbol{Y} \overset{ind}{\sim} \mathcal{N}(\boldsymbol{X\beta}, \sigma^2\boldsymbol{I}_n)$.

Para demostrar la independencia de los estimadores $\hat{\boldsymbol{\beta}}$ y $\frac{n\hat{\sigma}^2_{MLE}}{\sigma^2}$, tratemos de hallar la distribución de la forma cuadrática asociada al vector normal multivariante $\hat{\boldsymbol{\beta}} \sim \mathcal{N}_{p+1}(\boldsymbol{\beta}, \sigma^2(\boldsymbol{X^T X})^{-1})$ y relacionarlo con el vector $\boldsymbol{Y} \overset{ind}{\sim} \mathcal{N}(\boldsymbol{X\beta}, \sigma^2\boldsymbol{I}_n)$, para poder expresar dicha forma cuadrática como $\frac{1}{\sigma^2}\boldsymbol{Y}^T\boldsymbol{BY}$, de modo que, aplicando el Teorema 1.2 obtengamos la independencia de ambos. Obsérvese que $\hat{\boldsymbol{\beta}} \sim \mathcal{N}_{p+1}(\boldsymbol{\beta}, \sigma^2(\boldsymbol{X}^T\boldsymbol{X})^{-1})$, por lo que podemos expresar dicha distribución de la forma cuadrática asociada a $\hat{\boldsymbol{\beta}}$ como $\frac{1}{\sigma^2}\hat{\boldsymbol{\beta}}^T(\boldsymbol{X}^T\boldsymbol{X})\hat{\boldsymbol{\beta}}$. Ahora bien, desarrollando el valor de la expresión obtenemos $\frac{1}{\sigma^2}\hat{\boldsymbol{\beta}}^T(\boldsymbol{X}^T\boldsymbol{X})\hat{\boldsymbol{\beta}} = \frac{1}{\sigma^2}(\boldsymbol{X}\hat{\boldsymbol{\beta}})^T(\boldsymbol{X}\hat{\boldsymbol{\beta}}) = \frac{1}{\sigma^2}\hat{\boldsymbol{Y}}^T\hat{\boldsymbol{Y}}$ y por la Definición 6, sabemos que $\hat{\boldsymbol{Y}} = \boldsymbol{HY}$, por lo que $\frac{1}{\sigma^2}\hat{\boldsymbol{Y}}^T\hat{\boldsymbol{Y}} = \frac{1}{\sigma^2}(\boldsymbol{HY})^T(\boldsymbol{HY}) = \frac{1}{\sigma^2}\boldsymbol{Y}^T(\boldsymbol{H}^T\boldsymbol{H})\boldsymbol{Y}$ y por la Proposición 1.1, obtenemos que es igual a $\frac{1}{\sigma^2}\boldsymbol{Y}^T\boldsymbol{HY}$. De este modo, llamando $\boldsymbol{B} = \boldsymbol{H}$, hemos logrado expresar ambas formas cuadráticas de manera que se hallan relacionadas con el vector $\boldsymbol{Y} \overset{ind}{\sim} \mathcal{N}(\boldsymbol{X\beta}, \sigma^2\boldsymbol{I}_n)$. Por el Teorema 1.2 obtenemos que son independientes ya que $\boldsymbol{AB} = (\boldsymbol{I}_n - \boldsymbol{H})\boldsymbol{H} = \boldsymbol{0}_{n\times n}$ por las propiedades de la matriz hat recogidas en 1.1, como se quería demostrar.

□